Raport z etapu 3

Przetwarzanie dużych zbiorów danych

Szymon Jędrzejczak (266867)
Mateusz Nasewicz (268513)
Szymon Wieczorek (266586)

25.03.2026

Spis treści

1 Wstęp **2**

2 Poziom 1: Struktura analitycznej bazy danych **2**
2.1 Specyfikacja atrybutów zbioru 2

3 Algorytmiczna definicja wskaźników analitycznych **2**
3.1 Modele oparte na potencjale grawitacyjnym (handel, gastronomia, rekreacja) 3
3.2 Edukacja: Grawitacyjny indeks oświatowy (`indeks_grawitacyjny_edukacji`) 3
3.3 Transport: Ważona przepustowość GTFS (`wskaznik_przepustowosci_gtfs`) 3
3.4 Hałas: Ważony współczynnik narażenia drogowego (`wspolczynnik_narazenia_halas`) . . . 3

4 Poziom 2: Końcowe zbiory i reprezentacje **4**

1 Wstęp

Celem tego etapu jest zbadanie korelacji ofertowych cen mieszkań z dostępnością infrastruktury miejskiej (POI) oraz jakością komunikacji zbiorowej. Dokument definiuje format, struktury oraz ostateczną zawartość danych wynikowych.

2 Poziom 1: Struktura analitycznej bazy danych

Pierwszym etapem produkcji danych wynikowych jest przetworzenie źródeł w rozproszonym środowisku obliczeniowym (Apache Spark). Połączone zostaną: rejestr cen nieruchomości, zrzuty przestrzenne OpenStreetMap oraz rozkłady jazdy GTFS.

- **Struktura zbioru:** Płaska tabela analityczna. Każdy wiersz reprezentuje jedną ofertę mieszkaniową, opisaną zestawem wyliczonych przestrzennych wskaźników odległościowych.
- **Format zapisu: Parquet**. Wybór tego formatu podyktowany jest wysoką wydajnością oraz natywną integracją z bibliotekami uczenia maszynowego (np. Scikit-learn).

2.1 Specyfikacja atrybutów zbioru

Wszystkie nowe atrybuty są wyliczane w locie przez klastry Hadoop na podstawie dystansu i algorytmów grawitacyjnych, co oznacza, że przyjmują ciągłe wartości zmiennoprzecinkowe.

Tabela 2.1: Specyfikacja struktury głównego zbioru analitycznego

Nazwa atrybutu	Typ danych	Pochodzenie	Przykładowa zawartość
Atrybuty bazowe (pochodzące ze zbioru ofert nieruchomości)			
`id_oferty`	`Integer`	Oferty mieszkaniowe	1048592
`miejscowosc`	`String`	Oferty mieszkaniowe	Warszawa
`powierzchnia_m2`	`Float`	Oferty mieszkaniowe	54.5
`cena_calkowita_zl`	`Float`	Oferty mieszkaniowe	845000.00
`cena_za_m2`	`Float`	Oferty mieszkaniowe	15504.58
`lat` (szerokość geogr.)	`Float`	Oferty mieszkaniowe / Geokodowanie	52.241387
`lon` (długość geogr.)	`Float`	Oferty mieszkaniowe / Geokodowanie	20.980452
Atrybuty algorytmiczne wyznaczone w procesie Map-Reduce			
`indeks_potencjalu_handlu`	`Float`	Algorytm grawit. (OSM)	12.871
`indeks_potencjalu_gastro`	`Float`	Algorytm grawit. (OSM)	8.904
`indeks_potencjalu_rekreacji`	`Float`	Algorytm grawit. (OSM)	5.112
`indeks_grawitacyjny_edukacji`	`Float`	Algorytm eksponenc. (OSM)	3.452
`wskaznik_przepustowosci_gtfs`	`Float`	Agregacja popytu (GTFS)	154.22
`wspolczynnik_narazenia_halas`	`Float`	Dystans minimalny (OSM)	0.853

3 Algorytmiczna definicja wskaźników analitycznych

Aby badanie statystyczne w pełni odzwierciedlało użyteczność przestrzenną, zastosowano podejście oparte na uogólnionych modelach grawitacyjnych.

3.1 Modele oparte na potencjale grawitacyjnym (handel, gastronomia, rekreacja)

Dla trzech kluczowych filarów "miasta 15-minutowego" zastosowano wzór definiujący całkowitą dostępność przestrzenną (oparty na modelu Huffa). Faworyzuje on duże obiekty w bliskim sąsiedztwie:

$$I_{kategoria} = \sum_{j=1}^{n} \left(\frac{W_j}{d_{ij}^{\beta}} \right)$$

gdzie d_{ij} to odległość od mieszkania do obiektu j, β to parametr tarcia przestrzennego (np. $\beta = 2$ dla ruchu pieszego), a W_j to waga przypisana do konkretnego punktu z zależności od dziedziny:

- **Handel (`indeks_potencjalu_handlu`):** Wagę W_j determinuje typ sklepu wyekstrahowany z tagów `shop`. Supermarkety i galerie handlowe zyskują wysoki mnożnik atrakcyjności, podczas gdy małe sklepy osiedlowe niższy. Dokładne wartości współczynników zostaną jeszcze określone.
- **Gastronomia (`indeks_potencjalu_gastro`):** Wagą W_j jest typ lokalu (`amenity=restaurant` vs `cafe`). Zagęszczenie wysoko punktowanych restauracji na krótkim dystansie generuje skokowy wzrost wskaźnika, modelując strefy tętniących życiem rynków miejskich.
- **Rekreacja (`indeks_potencjalu_rekreacji`):** Dla obiektów poligonowych (parki, lasy) jako wagę W_j zaprojektowano fizyczne pole powierzchni obszaru zielonego. Dzięki temu rozległe parki krajobrazowe utrzymują silny wpływ grawitacyjny na cenę mieszkań nawet ze znacznych odległości, podczas gdy małe place zabaw punktują jedynie lokalnie.

3.2 Edukacja: Grawitacyjny indeks oświatowy (`indeks_grawitacyjny_edukacji`)

Wykorzystuje funkcję nieliniowego zaniku dystansu (wykładniczego), odzwierciedlając niechęć rodziców do prowadzenia dzieci na dalekie odległości.

$$I_{edukacja} = \sum e^{-\alpha \cdot d_i}$$

gdzie α to stała wygasania (np. 0.002), a d_i to odległość do placówki `amenity=school` lub `kindergarten`.

3.3 Transport: Ważona przepustowość GTFS (`wskaznik_przepustowosci_gtfs`)

Algorytm agreguje dane z 4 połączonych plików relacyjnych. Zamiast liczyć przystanki, wylicza stosunek liczby porannych kursów do dystansu pieszego. Dla każdego przystanku k w promieniu dojścia:

$$I_{transport} = \sum \left(\frac{K_k}{d_k} \right)$$

gdzie K_k to sumaryczna liczba odjazdów w dni robocze między godziną 07:00 a 09:00.

3.4 Hałas: Ważony współczynnik narażenia drogowego (`wspolczynnik_narazenia_halas`)

Zamiast opierać się na samej odległości do jakiejkolwiek drogi, opracowano algorytm uwzględniający specyfikację techniczną infrastruktury drogowej (odczytywaną z tagów OSM). Wskaźnik modelujący uciążliwość akustyczną wyrażony jest wzorem:

$$I_{halas} = \frac{W_{drogi} \cdot L_{pasow}}{D_{min}}$$

gdzie:

- W_{drogi} to waga uciążliwości wynikająca z hierarchii i klasy drogi (tag `highway`). Trasy szybkiego ruchu (`motorway`, `trunk`) otrzymują najwyższe wagi (np. 10), drogi główne (`primary`) wagi wysokie (np. 7), drogi zbiorcze (`secondary`) wagi średnie (np. 4), a drogi osiedlowe (`residential`) są ignorowane (waga 0), gdyż nie obniżają wartości lokalu.
- L_{pasow} to liczba pasów ruchu odczytana z tagu `lanes`, działająca jako bezpośredni mnożnik natężenia ruchu. (Algorytm można dodatkowo skalibrować o tagi `maxspeed` oraz `surface`.)
- D_{min} to najkrótsza odległość od nieruchomości do najbliższego uwzględnianego segmentu drogowego.

Konstrukcja matematyczna algorytmu powoduje, że bliskość wielopasmowej arterii znacząco zwiększa wartość wskaźnika, co może pokazać negatywną korelację hałasu z ceną ofertową m^2.

4 Poziom 2: Końcowe zbiory i reprezentacje

Po wygenerowaniu opisanej bazy analitycznej, przeprowadzona zostanie finalna analiza eksploracyjna. Na jej podstawie będzie można wyznaczyć:

1. **Macierz korelacji:** Obliczenie współczynników Pearsona pomiędzy ceną ofertową a wyliczonymi algorytmami, pokazując wektory i siłę wpływu zmiennych na rynek nieruchomości.

2. **Geoprzestrzenna heatmapa (OpenStreetMap):** Wykorzystanie bibliotek analitycznych (np. Folium) do wygenerowania mapy renderującej plamy ciepła (ceny ofertowe) z nałożoną warstwą punktową, lokalizującą infrastrukturę o najwyższym wyliczonym potencjale grawitacyjnym.