Raport z etapu 4

Przetwarzanie dużych zbiorów danych

Szymon Jędrzejczak (266867)
Mateusz Nasewicz (268513)
Szymon Wieczorek (266586)

08.04.2026

Spis treści

1 Wstęp **2**

2 Diagram przepływu danych **2**

3 Opis etapów przetwarzania **3**
3.1 E1.1 – Ekstrakcja i normalizacja GTFS . . . 3
3.2 E1.2 – Ekstrakcja i normalizacja OSM . . . 3
3.3 E1.3 – Ekstrakcja i normalizacja ofert mieszkań . . . 3
3.4 E1.5 – Pre-agregacja GTFS per przystanek . . . 4
3.5 E2 – Obliczanie wskaźników per nieruchomość . . . 4
3.6 E3 – Macierz korelacji . . . 5

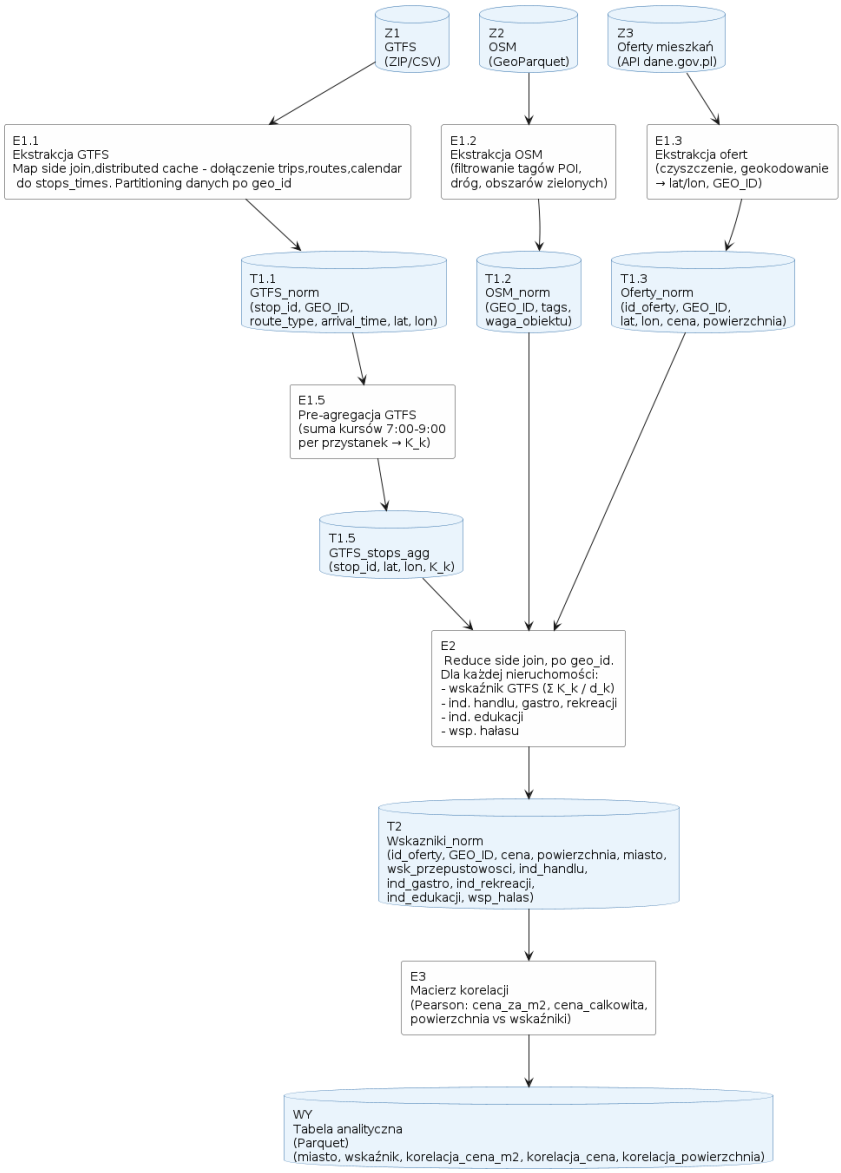
4 Zbiory danych tymczasowych **5**
4.1 T1.1 – Znormalizowane dane GTFS . . . 5
4.2 T1.2 – Znormalizowane obiekty OSM . . . 6
4.3 T1.3 – Znormalizowane oferty mieszkaniowe . . . 6
4.4 T1.5 – Agregat przepustowości GTFS per przystanek . . . 6
4.5 T2 – Wskaźniki analityczne per nieruchomość . . . 7

1 Wstęp

Celem niniejszego etapu jest zaprojektowanie i opisanie procesów przetwarzania danych w rozproszonym środowisku obliczeniowym. Dokument definiuje przepływ danych pomiędzy poszczególnymi etapami transformacji – od ekstrakcji i normalizacji surowych źródeł, przez obliczanie wskaźników analitycznych per nieruchomość, aż po wyznaczenie finalnej macierzy korelacji.

2 Diagram przepływu danych

Poniższy diagram przedstawia pełny przepływ danych – od źródeł przez kolejne etapy transformacji do tabeli wynikowej.



Rysunek 2.1: Diagram przepływu danych w opracowanym potoku

3 Opis etapów przetwarzania

3.1 E1.1 – Ekstrakcja i normalizacja GTFS

Etap ten przetwarza dane transportowe ze źródła Z1 (archiwa ZIP w formacie GTFS). Przy użyciu techniki *Map Side Join* z *Distributed Cache* następuje złączenie pięciu plików relacyjnych: `stop_times.txt`, `trips.txt`, `routes.txt`, `calendar.txt` oraz `stops.txt`. Wynikowy zbiór jest partycjonowany po kluczu `GEO_ID` w celu optymalizacji późniejszych złączeń przestrzennych.

Tabela 3.1: Specyfikacja transformacji atrybutów – E1.1

Atrybut wyjściowy	Atrybuty wejściowe	Operacja
`stop_id`	`stop_id` (stops.txt)	Przekazanie 1:1
`lat`	`stop_lat` (stops.txt)	Przekazanie 1:1
`lon`	`stop_lon` (stops.txt)	Przekazanie 1:1
`GEO_ID`	`stop_lat`, `stop_lon`	Geohash / binning przestrzenny
`route_type`	`route_type` (routes.txt)	Map Side Join po `route_id`
`arrival_time`	`arrival_time` (stop_times.txt)	Map Side Join po `trip_id`

3.2 E1.2 – Ekstrakcja i normalizacja OSM

Etap przetwarza dane przestrzenne ze źródła Z2 (GeoParquet). Filtrowane są węzły i obiekty poligonowe odpowiadające kategoriom POI istotnym analitycznie: handel, gastronomia, rekreacja, edukacja oraz infrastruktura drogowa. Każdemu obiektowi przypisywana jest waga `waga_obiektu` na podstawie jego typu.

Tabela 3.2: Specyfikacja transformacji atrybutów – E1.2

Atrybut wyjściowy	Atrybuty wejściowe	Operacja
`GEO_ID`	`lat`, `lon` (nodes)	Geohash / binning przestrzenny
`lat`	`lat`	Przekazanie 1:1
`lon`	`lon`	Przekazanie 1:1
`tags`	`tags`	Filtrowanie wg kategorii POI, dróg, zieleni
`waga_obiektu`	`tags` (typ obiektu)	Przypisanie wagi wg słownika typów

3.3 E1.3 – Ekstrakcja i normalizacja ofert mieszkań

Etap pobiera dane z REST API dane.gov.pl (źródło Z3) i przeprowadza ich czyszczenie oraz geokodowanie. Dla każdej oferty wyznaczane są współrzędne geograficzne (`lat`, `lon`), a następnie generowany jest przestrzenny identyfikator `GEO_ID`.

Geokodowanie realizowane jest przy użyciu lokalnej instancji serwera Nominatim uruchomionej w środowisku Docker, zasilanej tym samym zrzutem OSM co źródło Z2. Takie podejście eliminuje ograniczenia przepustowości zewnętrznych API oraz pozwala na pełną równoległość geokodowania w środowisku rozproszonym. Wynik geokodowania jest zapisywany jednorazowo w systemie HDFS jako zbiór T1.3, dzięki czemu kolejne etapy nie wymagają ponownego odpytywania serwera.

Tabela 3.3: Specyfikacja transformacji atrybutów – E1.3

Atrybut wyjściowy	Atrybuty wejściowe	Operacja
id_oferty	id_oferty	Przekazanie 1:1
lat, lon	ulica, nr_nieruchomosci, miejscowosc	Geokodowanie adresu (lokalny Nominatim)
GEO_ID	lat, lon	Geohash / binning przestrzenny
cena	cena_za_m2, cena_calkowita_zl	Przekazanie 1:1
powierzchnia	powierzchnia_uzytkowa_m2	Przekazanie 1:1

3.4 E1.5 – Pre-agregacja GTFS per przystanek

Przed obliczeniem wskaźnika transportowego per nieruchomość wyznaczany jest niezależny wskaźnik przepustowości dla każdego przystanku. Wartość K_k reprezentuje sumaryczną liczbę odjazdów w godzinach szczytu porannego (7:00–9:00) w dni robocze. Etap ten jest logicznie odseparowany od E2, co pozwala uniknąć wielokrotnego przeliczania tej samej wartości dla każdej pary przystanek–nieruchomość.

Tabela 3.4: Specyfikacja transformacji atrybutów – E1.5

Atrybut wyjściowy	Atrybuty wejściowe	Operacja
stop_id	stop_id	Przekazanie 1:1
lat	lat	Przekazanie 1:1
lon	lon	Przekazanie 1:1
K_k	arrival_time	COUNT odjazdów w oknie 7:00–9:00 per stop_id

3.5 E2 – Obliczanie wskaźników per nieruchomość

Jest to centralny etap przetwarzania. Przy użyciu techniki *Reduce Side Join* po kluczu GEO_ID łączone są trzy zbiory tymczasowe: T1.2 (OSM), T1.3 (oferty) oraz T1.5 (przystanki GTFS). Dla każdej nieruchomości obliczane są wszystkie wskaźniki analityczne zdefiniowane w etapie 3.

Obsługa granic siatki geohash Złączenie przestrzenne uwzględnia nie tylko komórkę GEO_ID danej nieruchomości, lecz także 8 sąsiadujących komórek. Eliminuje to błędy wynikające z podziału przestrzeni na granicach siatki – obiekt POI lub przystanek fizycznie bliski nieruchomości, lecz leżący w sąsiedniej komórce, zostaje prawidłowo uwzględniony w obliczeniach. Przyjęta precyzja geohash to poziom 6 (rozmiar komórki $\approx 1.2 \times 1.2$ km), odpowiedni dla analiz dostępności pieszej w skali miejskiej.

Konfigurowalny promień dojścia Promień dojścia do przystanku komunikacji miejskiej stosowany przy obliczaniu wsk_przepustowosci jest konfigurowalnym parametrem potoku (wartość domyślna: 800 m). W środowisku Hadoop przekazywany jest przez konfigurację zadania:

```
-D pipeline.walking.radius.m=800
```

W środowisku Spark wszystkie parametry potoku (promień dojścia, okno godzinowe GTFS, współczynniki β i α modeli grawitacyjnych) są gromadzone w jednym słowniku konfiguracyjnym i dystrybuowane do węzłów wykonawczych za pomocą mechanizmu broadcast:

```
params = {
    "walking_radius_m":  800,
    "gtfs_peak_start":   "07:00",
    "gtfs_peak_end":     "09:00",
    "gravity_beta":      2.0,
    "education_alpha":   0.002
```

```
}
params_bc = spark.sparkContext.broadcast(params)
```

Tabela 3.5: Specyfikacja transformacji atrybutów – E2

Atrybut wyjściowy	Atrybuty wejściowe	Operacja
id_oferty, GEO_ID, cena, powierzchnia, miasto	T1.3	Przekazanie 1:1
wsk_przepustowosci	K_k, lat/lon (T1.5 i T1.3)	$\sum K_k/d_k$ dla przystanków w promieniu dojścia
ind_handlu	tags, waga_obiektu, lat/lon (T1.2)	$\sum W_j/d_{ij}^2$ (model Huffa)
ind_gastro	tags, waga_obiektu, lat/lon (T1.2)	$\sum W_j/d_{ij}^2$ (model Huffa)
ind_rekreacji	tags, waga_obiektu, lat/lon (T1.2)	$\sum W_j/d_{ij}^2$, W_j = powierzchnia obszaru
ind_edukacji	tags, lat/lon (T1.2)	$\sum e^{-\alpha \cdot d_i}$
wsp_halas	tags (highway, lanes), lat/lon (T1.2)	$W_{drogi} \cdot L_{pasow}/D_{min}$

3.6 E3 – Macierz korelacji

Finalny etap oblicza współczynniki korelacji Pearsona pomiędzy każdym z wyliczonych wskaźników a trzema zmiennymi cenowymi: cena_za_m2, cena_calkowita_zl oraz powierzchnia_m2. Wyniki są grupowane według miasta (miejscowosc), co umożliwia porównanie siły i kierunku zależności w różnych ośrodkach miejskich.

Tabela 3.6: Specyfikacja transformacji atrybutów – E3

Atrybut wyjściowy	Atrybuty wejściowe	Operacja
miasto	miasto (T2)	GROUP BY miejscowosc
wskaznik	nazwa kolumny wskaźnika	Iteracja po kolumnach wskaźnikowych
korelacja_cena_m2	cena_za_m2, wskaźnik	Pearson(cena_za_m2, wskaźnik)
korelacja_cena	cena_calkowita_zl, wskaźnik	Pearson(cena_calkowita, wskaźnik)
korelacja_powierzchnia	powierzchnia, wskaźnik	Pearson(powierzchnia, wskaźnik)

4 Zbiory danych tymczasowych

Wszystkie zbiory tymczasowe zapisywane są w formacie Parquet w systemie HDFS, co zapewnia natywną integrację zarówno z modelem Map-Reduce, jak i silnikiem Spark. Szacunki rozmiaru odnoszą się do danych po ekstrakcji i filtrowaniu, przed obliczeniem wskaźników.

4.1 T1.1 – Znormalizowane dane GTFS

Format: Parquet **Szacowany rozmiar:** ∼1 GB **Liczba wierszy:** ∼8 mln (jeden wiersz per odjazd ze przystanku)

Tabela 4.1: Przykładowe rekordy – T1.1

stop_id *(Integer)*	**lat** *(Float)*	**lon** *(Float)*	**GEO_ID** *(String)*	**route_type** *(Integer)*	**arrival_time** *(String)*
2228	52.231145	20.975310	u3qcvh	3	07:04:00
5	52.188762	20.962959	u3qc9e	0	07:11:00
1042	52.254301	21.012874	u3qcyn	3	08:47:00

4.2 T1.2 – Znormalizowane obiekty OSM

Format: Parquet **Szacowany rozmiar:** ∼400 MB **Liczba wierszy:** ∼5 mln (przefiltrowane węzły i poligony dla Polski)

Tabela 4.2: Przykładowe rekordy – T1.2

GEO_ID *(String)*	**lat** *(Float)*	**lon** *(Float)*	**tags** *(Array of Tuples)*	**waga_obiektu** *(Float)*
u3qcvh	52.232011	20.976450	[('shop', 'supermarket'), ('name', 'Biedronka')]	3.0
u3qcyn	52.255102	21.013560	[('amenity', 'restaurant'), ('name', 'Sushi Zushi')]	2.0
u3qc9e	52.189774	20.963821	[('leisure', 'park'), ('name', 'Park Szczęśliwicki')]	141600.0

Wartość `waga_obiektu` dla obiektów powierzchniowych (parki, lasy) odpowiada polu powierzchni obszaru w m^2; dla obiektów punktowych jest to stały mnożnik atrakcyjności wynikający ze słownika typów.

4.3 T1.3 – Znormalizowane oferty mieszkaniowe

Format: Parquet **Szacowany rozmiar:** ∼3 GB **Liczba wierszy:** ∼1,5 mln ofert (surowe dane z całego kraju)

Tabela 4.3: Przykładowe rekordy – T1.3

id_oferty *(Integer)*	**lat** *(Float)*	**lon** *(Float)*	**GEO_ID** *(String)*	**cena_za_m2** *(Float)*	**cena_calkowita_zl** *(Integer)*	**powierzchnia_m2** *(Float)*
1048592	52.241387	20.980452	u3qcvh	15504.58	845000	54.5
1048601	52.196204	20.958713	u3qc9e	12837.20	513488	40.0
1048744	53.121893	18.003451	u3mhj4	9319.40	380231	40.8

4.4 T1.5 – Agregat przepustowości GTFS per przystanek

Format: Parquet **Szacowany rozmiar:** <10 MB **Liczba wierszy:** ∼25 tys. (jeden wiersz per przystanek)

Tabela 4.4: Przykładowe rekordy – T1.5

stop_id *(Integer)*	**lat** *(Float)*	**lon** *(Float)*	**K_k** *(Integer)*
2228	52.231145	20.975310	47
5	52.188762	20.962959	12
1042	52.254301	21.012874	31

4.5 T2 – Wskaźniki analityczne per nieruchomość

Format: Parquet **Szacowany rozmiar:** ∼3 GB **Liczba wierszy:** równa liczbie ofert w T1.3 (∼1,5 mln)

Tabela 4.5: Przykładowe rekordy – T2

id_oferty *(Integer)*	**miasto** *(String)*	**cena_za_m2** *(Float)*	**pow.** *(Float)*	**wsk_prze.** *(Float)*	**ind_handlu** *(Float)*	**ind_gastro** *(Float)*	**ind_rekr.** *(Float)*	**ind_eduk.** *(Float)*	**wsp_halas** *(Float)*
1048592	Warszawa	15504.58	54.5	154.22	12.871	8.904	5.112	3.452	0.853
1048601	Warszawa	12837.20	40.0	63.40	5.214	3.102	9.870	2.190	0.112
1048744	Bydgoszcz	9319.40	40.8	28.11	3.540	1.872	2.340	1.780	1.204

Kolumny `wsk_prze.`, `ind_rekr.` itd. są skrótami użytymi ze względu na szerokość tabeli. Wyższa wartość `wsp_halas` dla oferty z Bydgoszczy wskazuje na większe narażenie akustyczne (bliskość drogi wielopasmowej), co zgodnie z założeniami modelu powinno wykazywać ujemną korelację z ceną m^2.