Raport z etapu 6

Przetwarzanie dużych zbiorów danych

Szymon Jędrzejczak (266867)
Mateusz Nasewicz (268513)
Szymon Wieczorek (266586)

22.04.2026

Spis treści

1 Architektura i proces akwizycji danych **2**
1.1 Akwizycja danych komunikacyjnych (GTFS) 2
1.2 Akwizycja danych przestrzennych (OpenStreetMap) 2
1.3 Akwizycja danych deweloperskich (API Nieruchomości) 2

2 Dzienniki akwizycji danych i weryfikacja replikacji **3**
2.1 Dziennik procesu akwizycji 3
2.2 Weryfikacja replikacji w HDFS 4

1 Architektura i proces akwizycji danych

W ramach realizacji zadania zaimplementowano zautomatyzowany proces pobierania danych z trzech niezależnych źródeł. Dane są zapisywane w systemie plików HDFS na platformie Hadoop z zachowaniem wymogu 3 replik. Proces loguje czas pobrania, rozmiar danych, status oraz ewentualne błędy. Zapisywane są także metadane pobranych zbiorów danych, by ułatwić późniejszą ich aktualizacje.

Listing 1: Przykładowa zawartość pliku metadata.json

```
{
    "gtfs": {
        "filename": "20260421_20260430.zip"
    },
    "osm": {
        "etag": "\"3896678450\"",
        "size": "4934127975"
    },
    "4982": {
        "modified": "2025-07-13T12:03:07Z",
        "content_length": "757468"
    },
    "4898": {
        "modified": "2026-04-22T03:25:21Z",
        "content_length": "40230"
    },
    "4970": {
        "modified": "2026-04-22T03:54:57Z",
        "content_length": "8579"
    },
    "4899": {
        "modified": "2026-04-22T03:46:15Z",
        "content_length": "34578"
    },
}
```

1.1 Akwizycja danych komunikacyjnych (GTFS)

Dane GTFS pobierane są z serwera FTP (ftp://gtfs.ztm.waw.pl). Ponieważ pliki aktualizowane są bardzo często (prawie codziennie), skrypt weryfikuje nazwy plików pod kątem daty, aby pobrać i zapisać w HDFS wyłącznie najnowszą wersję, której jeszcze nie ma w klastrze. Pobieranie najnowszej wersji odbywa się tylko wtedy, gdy metadane z najnowszej wersji zdalnego zasobu nie zgadzają się z przechowywanymi lokalnie metadanymi.

1.2 Akwizycja danych przestrzennych (OpenStreetMap)

Zbiór danych OSM w formacie Parquet pobierany jest z serwera HTTP. Ze względu na rzadsze aktualizacje (kilka razy w miesiącu), proces akwizycji zachowuje metadane nagłówków HTTP (`ETag` oraz `Content-Length`). Pobieranie najnowszej wersji odbywa się tylko wtedy, gdy metadane z najnowszej wersji zdalnego zasobu nie zgadzają się z przechowywanymi lokalnie metadanymi.

1.3 Akwizycja danych deweloperskich (API Nieruchomości)

Dane na temat nieruchomości pobierane są za pośrednictwem dedykowanego rządowego API. Każdy deweloper udostępnia codziennie jeden nowy plik. Skrypt skanuje dostępne zbiory danych i pobiera wyłącznie te archiwa, których metadane zdalnego zasobu nie zgadzają się z przechowywanymi lokalnie metadanymi (modified date). Dane przed zapisaniem w systemie plików HDFS zostają scalone (wiele małych plików w ramach każdego dewelopera), a następnie rozdzielone na części, każda po 128 MB.

2 Dzienniki akwizycji danych i weryfikacja replikacji

2.1 Dziennik procesu akwizycji

Poniżej przedstawiono zawartość dziennika (log), który dokumentuje działanie procesu. Dziennik zawiera informacje o czasie operacji, statusie procesu oraz ewentualnych błędach z systemów źródłowych.

```
2026-04-22 11:57:37,185 [INFO] Sprawdzanie źródła: gtfs
2026-04-22 11:57:37,797 [INFO] Najnowszy plik na FTP to: 20260421_20260430.zip
2026-04-22 11:57:37,832 [INFO] Wykryto nową wersję zasobu [gtfs]. Rozpoczynam aktualizację
↪  lokalnych plików...
2026-04-22 11:58:02,170 [INFO] Pobrano plik FTP: 49.42 MB (20260421_20260430.zip)
2026-04-22 11:58:03,611 [INFO] Zakończono aktualizację gtfs.
2026-04-22 11:58:03,611 [INFO] Sprawdzanie źródła: osm
2026-04-22 11:58:03,760 [INFO] Metadane OSM Poland | ETag: "3896678450" | Size: 4934127975
2026-04-22 11:58:03,761 [INFO] Wykryto nową wersję zasobu [osm]. Rozpoczynam aktualizację
↪  lokalnych plików...
2026-04-22 11:59:55,977 [INFO] Pobrano plik: 4705.55 MB z
↪  https://download3.bbbike.org/osm/parquet/region/europe/poland/poland.osm.parquet.zip
2026-04-22 12:00:34,304 [INFO] Zakończono aktualizację osm.
2026-04-22 12:00:34,304 [INFO] === URUCHAMIANIE SKANERA DEWELOPERÓW (MULTI-THREAD) ===
2026-04-22 12:00:36,104 [INFO] GET
↪  https://api.dane.gov.pl/1.4/datasets?keyword%5Bcontains%5D=Deweloper&per_page=100 -> 200
2026-04-22 12:00:37,224 [INFO] Pobrano plik: 0.05 MB z
↪  https://api.dane.gov.pl/datasets/4997,ceny-ofertowe-mieszkan-i-przynaleznosci-dewelopera/res
2026-04-22 12:00:37,225 [INFO] [Worker 15] Zakończono pobieranie:
↪  https://api.dane.gov.pl/datasets/4997,ceny-ofertowe-mieszkan-i-przynaleznosci-dewelopera/res
↪  Pobrano 0.05 MB
.
.
2026-04-22 12:29:11,916 [INFO] [Worker 06] Zakończono pobieranie:
↪  https://api.dane.gov.pl/datasets/31257,ceny-ofertowe-mieszkan-dewelopera-bosco-mickiewicza-g
↪  Pobrano 0.40 MB
2026-04-22 12:29:11,966 [INFO] [Worker 06] Rozpakowano i wyczyszczono:
↪  /home/mateusz/Github/duze-dane/data/real_estate/31257
2026-04-22 12:29:12,755 [INFO] Pobrano plik: 1.40 MB z
↪  https://api.dane.gov.pl/datasets/31109,ceny-ofertowe-mieszkan-dewelopera-robyg-jaboniowa-sp-
2026-04-22 12:29:12,755 [INFO] [Worker 09] Zakończono pobieranie:
↪  https://api.dane.gov.pl/datasets/31109,ceny-ofertowe-mieszkan-dewelopera-robyg-jaboniowa-sp-
↪  Pobrano 1.40 MB
2026-04-22 12:29:12,842 [INFO] [Worker 09] Rozpakowano i wyczyszczono:
↪  /home/mateusz/Github/duze-dane/data/real_estate/31109
2026-04-22 12:29:14,011 [INFO] Pobrano plik: 0.70 MB z
↪  https://api.dane.gov.pl/datasets/31219,ceny-ofertowe-mieszkan-dewelopera-domero-development-
2026-04-22 12:29:14,011 [INFO] [Worker 10] Zakończono pobieranie:
↪  https://api.dane.gov.pl/datasets/31219,ceny-ofertowe-mieszkan-dewelopera-domero-development-
↪  Pobrano 0.70 MB
2026-04-22 12:29:14,036 [INFO] [Worker 10] Rozpakowano i wyczyszczono:
↪  /home/mateusz/Github/duze-dane/data/real_estate/31219
2026-04-22 12:29:14,670 [INFO] Pobrano plik: 1.74 MB z
↪  https://api.dane.gov.pl/datasets/31261,ceny-ofertowe-mieszkan-dewelopera-firma-inwestycyjna-
2026-04-22 12:29:14,671 [INFO] [Worker 13] Zakończono pobieranie:
↪  https://api.dane.gov.pl/datasets/31261,ceny-ofertowe-mieszkan-dewelopera-firma-inwestycyjna-
↪  Pobrano 1.74 MB
2026-04-22 12:29:14,902 [INFO] [Worker 13] Rozpakowano i wyczyszczono:
↪  /home/mateusz/Github/duze-dane/data/real_estate/31261
2026-04-22 12:29:17,328 [INFO] Pobrano plik: 0.82 MB z
↪  https://api.dane.gov.pl/datasets/31254,ceny-ofertowe-mieszkan-dewelopera-wsd-spv-8-sp-z-oo-e
2026-04-22 12:29:17,328 [INFO] [Worker 12] Zakończono pobieranie:
↪  https://api.dane.gov.pl/datasets/31254,ceny-ofertowe-mieszkan-dewelopera-wsd-spv-8-sp-z-oo-e
↪  Pobrano 0.82 MB
2026-04-22 12:29:17,423 [INFO] [Worker 12] Rozpakowano i wyczyszczono:
↪  /home/mateusz/Github/duze-dane/data/real_estate/31254
```

```
2026-04-22 12:29:17,455 [INFO] === SKANOWANIE ZAKOŃCZONE ===
2026-04-22 12:29:17,456 [INFO] === Akwizycja zakończona ===
```

2.2 Weryfikacja replikacji w HDFS

Zgodnie z minimalnymi wymaganiami zadania, dane w systemie HDFS są przetrzymywane w 3 replikach.

Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
-rw-r--r--	root	supergroup	241 B	Apr 22 13:42	3	128 MB	agency.txt
-rw-r--r--	root	supergroup	388 B	Apr 22 13:42	3	128 MB	calendar.txt
-rw-r--r--	root	supergroup	35 B	Apr 22 13:42	3	128 MB	calendar_dates.txt
-rw-r--r--	root	supergroup	198 B	Apr 22 13:42	3	128 MB	feed_info.txt
-rw-r--r--	root	supergroup	1.41 MB	Apr 22 13:42	3	128 MB	routes.txt
-rw-r--r--	root	supergroup	19.86 MB	Apr 22 13:42	3	128 MB	shapes.txt
-rw-r--r--	root	supergroup	358.89 MB	Apr 22 13:42	3	128 MB	stop_times.txt
-rw-r--r--	root	supergroup	346.59 KB	Apr 22 13:42	3	128 MB	stops.txt
-rw-r--r--	root	supergroup	13.1 MB	Apr 22 13:42	3	128 MB	trips.txt

Rysunek 2.1: Pliki GTFS zapisane w HDFS

Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
-rw-r--r--	root	supergroup	202.89 MB	Apr 22 13:45	3	128 MB	node_0000.zstd.parquet
-rw-r--r--	root	supergroup	202.82 MB	Apr 22 13:46	3	128 MB	node_0001.zstd.parquet
-rw-r--r--	root	supergroup	202.57 MB	Apr 22 13:46	3	128 MB	node_0002.zstd.parquet
-rw-r--r--	root	supergroup	202.05 MB	Apr 22 13:46	3	128 MB	node_0003.zstd.parquet
-rw-r--r--	root	supergroup	202.98 MB	Apr 22 13:46	3	128 MB	node_0004.zstd.parquet
-rw-r--r--	root	supergroup	200.35 MB	Apr 22 13:45	3	128 MB	node_0005.zstd.parquet
-rw-r--r--	root	supergroup	204.21 MB	Apr 22 13:46	3	128 MB	node_0006.zstd.parquet
-rw-r--r--	root	supergroup	202.41 MB	Apr 22 13:46	3	128 MB	node_0007.zstd.parquet
-rw-r--r--	root	supergroup	204.34 MB	Apr 22 13:46	3	128 MB	node_0008.zstd.parquet
-rw-r--r--	root	supergroup	202.32 MB	Apr 22 13:46	3	128 MB	node_0009.zstd.parquet
-rw-r--r--	root	supergroup	203.3 MB	Apr 22 13:46	3	128 MB	node_0010.zstd.parquet
-rw-r--r--	root	supergroup	203.75 MB	Apr 22 13:46	3	128 MB	node_0011.zstd.parquet
-rw-r--r--	root	supergroup	203.78 MB	Apr 22 13:46	3	128 MB	node_0012.zstd.parquet
-rw-r--r--	root	supergroup	203.37 MB	Apr 22 13:46	3	128 MB	node_0013.zstd.parquet
-rw-r--r--	root	supergroup	201.58 MB	Apr 22 13:46	3	128 MB	node_0014.zstd.parquet
-rw-r--r--	root	supergroup	202.42 MB	Apr 22 13:46	3	128 MB	node_0015.zstd.parquet

Rysunek 2.2: Pliki OpenStreetMap zapisane w HDFS

/real_estate_merged Go!

Show 25 entries Search:

Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
-rw-r--r--	root	supergroup	128 MB	Apr 22 13:46	3	128 MB	part_00
-rw-r--r--	root	supergroup	128 MB	Apr 22 13:46	3	128 MB	part_01
-rw-r--r--	root	supergroup	128 MB	Apr 22 13:46	3	128 MB	part_02
-rw-r--r--	root	supergroup	128 MB	Apr 22 13:46	3	128 MB	part_03
-rw-r--r--	root	supergroup	128 MB	Apr 22 13:46	3	128 MB	part_04
-rw-r--r--	root	supergroup	128 MB	Apr 22 13:47	3	128 MB	part_05
-rw-r--r--	root	supergroup	128 MB	Apr 22 13:47	3	128 MB	part_06
-rw-r--r--	root	supergroup	128 MB	Apr 22 13:47	3	128 MB	part_07
-rw-r--r--	root	supergroup	128 MB	Apr 22 13:47	3	128 MB	part_08
-rw-r--r--	root	supergroup	128 MB	Apr 22 13:47	3	128 MB	part_09
-rw-r--r--	root	supergroup	128 MB	Apr 22 13:47	3	128 MB	part_10
-rw-r--r--	root	supergroup	128 MB	Apr 22 13:47	3	128 MB	part_11
-rw-r--r--	root	supergroup	128 MB	Apr 22 13:47	3	128 MB	part_12
-rw-r--r--	root	supergroup	128 MB	Apr 22 13:47	3	128 MB	part_13
-rw-r--r--	root	supergroup	128 MB	Apr 22 13:47	3	128 MB	part_14

Rysunek 2.3: Pliki cen ofertowych deweloperów zapisane w HDFS