Przetwarzanie dużych zbiorów danych - Projekt

Wprowadzenie

Celem zajęć projektowych jest praktyczne zastosowanie narzędzi masowego przetwarzania danych. Studenci pracują w grupach 3 osobowych realizując wspólnie wybrany temat - projekt. Projekt jest realizowany etapami, obowiązujące terminy zamieszczono w tabeli niżej. Poszczególne grupy projektowe uzgadniają z prowadzącym szczegółowy zakres projektu.

Warunki zaliczenia:

- Każdy etap projektu jest oceniany w terminie jego obowiązywania.
- Etap oddany z opóźnieniem o 1 zajęcia może otrzymać maksymalnie ocenę 3.5.
- Etap opóźniony o więcej niż 1 termin zajęć nie będzie oceniany.
- Ocena końcowa jest wyznaczana jako średnia ważona ocen z poszczególnych etapów projektu.

Harmonogram zajęć i wagi ocen etapów:

Termin	Zadanie (waga do średniej ocen)
2	**1. Założenia projektu (1)** Wstępne opracowanie założeń projektu. Wybór zbiorów danych źródłowych i określenie ich zawartości i dostępności. Wskazanie oczekiwanych wyników przetwarzania danych. Minimalne wymagania: Patrz niżej dla wymagań dotyczących danych źródłowych i wynikowych Wynik: Raport opisujący wstępne założenia projektu z jego tematem, krótkim opisem celu projektu i wstępnym opisem danych źródłowych i wynikowych.
3	**2. Dane źródłowe (1)** Wybór zbiorów danych i analiza ich zawartości. Weryfikacja dostępności danych i wskazanie metody ich pozyskania. Minimalne wymagania: 3 Zbiory danych o różnym formacie, strukturze i rozmiarze przekraczającym 100MG dla każdego ze zbiorów. W każdym zbiorze danych co najmniej 5 atrybutów różnych typów. Zbiory danych mogą być np. dostępne w postaci statycznej, nie podlegającej zmianie, do pobrania z systemu źródłowego. Zaleca się wykorzystanie co najmniej jednego źródła danych podlegającego modyfikacjom w systemie źródłowym i/lub dostępnego poprzez wykorzystanie API oferowanego przez system źródłowy. Wynik: Raport zawierający techniczny opis zawartości źródeł danych z opisem ich formatu i struktury, oczekiwanego rozmiaru. Dla każdego źródła danych opis zawartości ze wskazaniem atrybutów, ich typów i przykładowej zawartości.
4	**3. Dane wynikowe (1)** Określenie formatu, struktury i zawartości danych wynikowych. Minimalne wymagania: Wynikiem przetwarzania danych powinien być co najmniej jeden zbiór danych zawierający co najmniej 5 atrybutów pochodzących ze zbiorów źródłowych i 3 atrybuty wyznaczone w procesie przetwarzania danych.

	Wynik: Raport zawierający opis techniczny wynikowego zbioru danych ze wskazaniem jego formatu i struktury. Opis struktury zbioru wynikowego ze wskazaniem atrybutów, ich typów i przykładowej zawartości.
5	**4. Procesy przetwarzania danych (2)** Opracowanie sposobu wyznaczenia wynikowego zbioru danych na podstawie danych źródłowych. Wyróżnienie pośrednich etapów przetwarzania danych i uzyskiwanych danych tymczasowych. Minimalne wymagania: Co najmniej 3 etapy przetwarzania danych i 2 zbiory danych tymczasowych. Pobieranie danych z systemu źródłowego nie jest wliczane do etapów przetwarzania danych. Wymagana realizacja operacji łączenia danych z różnych źródeł, agregacji i transformacji danych. Wynik: Raport zawierający opis sposobu wyznaczenia danych tymczasowych i wynikowych na podstawie danych źródłowych. Opis zbiorów danych tymczasowych zawierający ich format i strukturę oraz szacunek rozmiaru. Dla każdego zbiory danych tymczasowych opis ich zawartości ze wskazaniem atrybutów, ich typów i przykładowej zawartości.
6	**5. Hadoop (1)** Instalacja i uruchomienie systemu Hadoop np. w środowisku Docker. Minimalne wymagania: Co najmniej 3 węzły wykonawcze w klastrze. Wynik: Raport dokumentujący instalacje i uruchomienie sytemu Hadoop.
7	**6. Akwizycja danych (1)** Pobranie danych źródłowych i ich zapisanie w systemie plików HDFS na platformie Hadoop. Automatyzacja pobierania danych podlegających zmianom w systemie źródłowym. Minimalne wymagania: Patrz wymagania dla danych źródłowych. Proces akwizycji danych powinien zapisywać dziennik pokazujących czas i rozmiar danych pobranych z systemów źródłowych wraz ze statusem procesu oraz informacjami o ewentualnych błędach. 3 repliki danych w systemie HDFS. Wynik: Raport dokumentujący proces akwizycji danych i automatyzacji ich pobierania oraz przykładowe dzienniki akwizycji danych.
9	**7. Map-Reduce (2)** Implementacja wybranych procesów przetwarzania danych w modelu Map-Reduce. Przygotowanie implementacji projektowanych wcześniej procesów przetwarzania danych przy wykorzystaniu modelu Map-Reduce na platformie Hadoop. Minimalne wymagania: Co najmniej 2 procesy z opisanych w wymaganiach dla procesów przetwarzania danych. Procesy przetwarzania danych powinny zapisywać dziennik pokazujących czas ich wykonania wraz ze statusem procesu oraz informacjami o ewentualnych błędach. Wynik: Raport dokumentujący implementacje procesów przetwarzania danych. Opracowany kod źródłowy. Raport powinien zawierać pomiary czasów trwania poszczególnych etapów przetwarzania danych.

10	**8. Instalacja SPARK (1)** Instalacja i uruchomienie platformy Spark w systemie Hadoop. Wynik: Raport dokumentujący instalacje i uruchomienie systemu Spark.
12	**9. Spark (2)** Implementacja procesów przetwarzania danych na platformie Spark. Przygotowanie implementacji projektowanych wcześniej procesów przetwarzania danych przy wykorzystaniu Spark na platformie Hadoop. Minimalne wymagania: Co najmniej 2 procesy z opisanych w wymaganiach dla procesów przetwarzania danych. Procesy przetwarzania danych powinny zapisywać dziennik pokazujących czas ich wykonania wraz ze statusem procesu oraz informacjami o ewentualnych błędach. Wynik: Raport dokumentujący implementacje procesów przetwarzania danych. Opracowany kod źródłowy. Raport powinien zawierać pomiary czasów trwania poszczególnych etapów przetwarzania danych.
13	**10. Przygotowanie środowiska Databricks Free Edition / BigQuery sandbox (1)** Konfiguracja i uruchomienie środowiska Databricks Free Edition lub BigQuery sandbox. Wynik: Raport dokumentujący instalacje i uruchomienie wybranego środowiska chmurowego.
14	**11. Cloud (2)** Implementacja procesów przetwarzania danych w chmurze. Przygotowanie implementacji projektowanych wcześniej procesów przetwarzania danych. Minimalne wymagania: Co najmniej 2 procesy z opisanych w wymaganiach dla procesów przetwarzania danych. Procesy przetwarzania danych powinny zapisywać dziennik pokazujących czas ich wykonania wraz ze statusem procesu oraz informacjami o ewentualnych błędach. Wynik: Raport dokumentujący implementacje procesów przetwarzania danych. Opracowany kod źródłowy. Raport powinien zawierać pomiary czasów trwania poszczególnych etapów przetwarzania danych.
15	**12. Podsumowanie (1)** Podsumowanie projektu i wybór najbardziej wydajnych narzędzi realizacji wszystkich procesów przetwarzania danych. Wynik: Raport dokumentujący wybór najbardziej wydajnych narzędzi realizacji poszczególnych procesów przetwarzania danych. Raport powinien zawierać pomiary czasów trwania poszczególnych etapów przetwarzania danych dla wybranych narzędzi.